

一种改进的鲸鱼优化算法

张 永, 陈 锋

(中国科学技术大学 信息科学技术学院, 合肥 230027)

摘 要: 针对鲸鱼优化算法(WOA)收敛速度慢、收敛精度低的问题,在提升性能的基础上保留 WOA 的简单性,提出一种改进的 WOA。利用分段 Logistic 混沌映射产生混沌序列对种群位置进行初始化,以维持全局搜索时初始种群的多样性。考虑算法的非线性优化过程和搜索过程中个体状态的差异性,在 WOA 中引入非线性自适应权重策略,以协调全局探索和局部开发能力。通过仿真测试比较改进算法和 WOA 在求解 6 个典型基准函数时的性能,实验结果表明,改进算法在寻优过程中能够保持初始种群多样性,且具有更快的收敛速度和更优的收敛精度。

关键词: 鲸鱼优化算法;函数优化;混沌映射;非线性;启发式优化算法

中文引用格式:张 永,陈 锋.一种改进的鲸鱼优化算法[J].计算机工程,2018,44(3):208-213,219.

英文引用格式:ZHANG Yong, CHEN Feng. A Modified Whale Optimization Algorithm[J]. Computer Engineering, 2018, 44(3): 208-213, 219.

A Modified Whale Optimization Algorithm

ZHANG Yong, CHEN Feng

(School of Information Science and Technology, University of Science and Technology of China, Hefei 230027, China)

[Abstract] To overcome the slow speed and low precision in convergence of the Whale Optimization Algorithm (WOA), to preserve the simplicity of the original algorithm while enhancing the performance, an improved WOA is proposed. Firstly, to maintain the diversity of the initial population in the global search, the population position is initialized by the chaotic sequence generated by the piecewise Logistic chaotic mapping. Secondly, considering the nonlinear optimization process of the algorithm and the difference of individual state in the search process, a nonlinear adaptive weighting strategy is introduced in the basic algorithm to coordinate the global exploration and local development. By the simulation, it compares the performance of the improved algorithm and the WOA on solving six typical benchmark functions. Experimental results show that the improved WOA preserves the initial population diversity in the process of optimization with better convergence speed and precision.

[Key words] Whale Optimization Algorithm (WOA); function optimization; chaos mapping; nonlinearity; heuristic optimization algorithm

DOI:10.3969/j.issn.1000-3428.2018.03.035

0 概述

在科学研究和工业应用中,很多计算问题都可以归结为具有非线性、不可微、多峰值特性的复杂优化问题。近年来,随着优化问题的复杂性增加,对于新的优化技术的需求愈加明显,因此,很多研究人员将启发式优化算法应用到科学和工业的不同分支中。但是根据没有免费的午餐定理^[1],即不存在解决所有优化问题的算法,因此,许多研究者提出需要新的启发式算法或者改进当前的启发式算法^[2-5],以适应当前的不同技术问题。

鲸鱼优化算法(Whale Optimization Algorithm,

WOA)是由文献[6]提出的启发式优化新算法。WOA的本质是模拟座头鲸的 bubble-net 狩猎策略,将座头鲸独有的狩猎行为演化成随机优化过程。该算法具有概念简单、易于实施、不需要梯度信息以及高局部最优规避能力等优点,能够解决不同种类的优化问题。目前,对 WOA 的相关研究已经陆续展开,理论方面有:文献[7]提出引入反向学习自适应策略的鲸鱼优化算法(AWOA),但其在一定程度上存在收敛速度慢的问题,文献[8]提出加强自适应 WOA,虽然该改进算法在求解桁架尺寸优化问题中表现出良好性能,但是其存在稳定性较差的问题;应用方面有:文献[9]使用 WOA 选择乳腺癌诊断方法

作者简介:张 永(1991—),男,硕士研究生,主研方向为模式识别、智能系统;陈 锋,副教授、博士。

收稿日期:2017-02-17 **修回日期:**2017-03-30 **E-mail:**zyong008@mail.ustc.edu.cn

中最佳特征子集,文献[10]将 WOA 应用到运输和物流领域并解决车辆燃料消耗的优化问题,文献[11]采用 WOA 解决最佳功率流(OPF)问题。然而,与其他基于种群的启发式算法类似,基本 WOA 同样存在收敛速度慢及收敛精度低的缺陷。

基于以上问题,提出一种改进的鲸鱼优化算法(Modified Whale Optimization Algorithm, MWOA)。首先利用分段 Logistic 混沌映射产生混沌序列对种群位置进行初始化,以保持初始种群多样性;然后引入非线性自适应权重策略,以协调全局探索和局部开发能力。为验证 MWOA 的优化效果,用 MWOA 对 6 个典型基准函数的优化问题进行测试,并与 AWOA、改进的粒子群算法(PSO)、改进的重力搜索算法(GSA)的优化结果进行比较。

1 鲸鱼优化算法

WOA 由 Mirjalili Seyedali 等人于 2016 年引入和开发。在 WOA 中,搜索空间中每一头座头鲸都是优化问题的候选解,可以称之为“搜索代理”。WOA 利用一组搜索代理来确定优化问题的全局最优,给定问题的搜索过程开始于初始的一组随机解(候选解),然后按照优化规则更新候选解直到满足结束条件。事实上,WOA 模拟的是座头鲸寻找和攻击猎物的狩猎行为,这种行为被称为 bubble-net 狩猎策略。bubble-net 狩猎模型如图 1 所示。




图1 座头鲸 bubble-net 狩猎行为示意图

1.1 猎物包围

座头鲸可以识别猎物的位置并包围它们,由于最优解决方案的猎物位置不是先验已知的,因此 WOA 假设目前最优候选解为目标猎物,其他的搜索代理通过“目标猎物”更新自己的位置。猎物包围行为的数学模型如下:

$$D = |C \cdot X^*(t) - X(t)| \quad (1)$$

$$X(t+1) = X^*(t) - A \cdot D \quad (2)$$

其中, D 是搜索代理与目标猎物的距离, t 是当前迭代次数, A 、 C 是系数向量, $X^*(t)$ 是目前最优解位置向量, $X(t)$ 是当前位置向量, $|$ 是绝对值符号, \cdot 是逐元素乘法。

如果有更好的最优解位置向量, $X^*(t)$ 应该在

当次迭代中更新。

A 、 C 计算公式如下:

$$A = 2a \cdot r_a - a \quad (3)$$

$$C = 2 \cdot r_c \quad (4)$$

其中, r_a 、 r_c 是 $[0,1]$ 之间的随机向量, a 在迭代过程中从 2 线性递减至 0。

1.2 bubble-net 狩猎策略

座头鲸围绕猎物沿螺旋路径移动,同时吐出气泡产生陷阱,此即围绕着猎物使用 bubble-net 策略进行狩猎。模型中,通过减少式(3)中的 a 值来实现收缩环绕机制, A 的波动范围随着 a 减少,由式(3)可得 A 是 $[-a,a]$ 区间内的随机值。设置 A 是 $[-1,1]$ 区间的随机值,则搜索代理新的位置会随机出现在其之前的位置和目前最优解位置之间的任意处。

采用式(5)模拟座头鲸的螺旋形狩猎行为:

$$X(t+1) = D' \cdot e^{bl} \cdot \cos(2\pi l) + X^*(t) \quad (5)$$

其中, $D' = |X^*(t) - X(t)|$, b 是定义对数螺旋线形状的常量, l 是 $[-1,1]$ 之间的随机量。

座头鲸收缩环绕的同时沿着螺旋形路径向猎物游动,为了模拟这种“同时”行为,建立如下位置更新数学模型:

$$X(t+1) = \begin{cases} X^*(t) - A \cdot D, & p < 0.5 \\ X^*(t) + D' \cdot e^{bl} \cdot \cos(2\pi l), & p \geq 0.5 \end{cases} \quad (6)$$

其中,变量 p 是 $[0,1]$ 之间的随机数, p 以相等的概率在 0 和 1 之间切换。

1.3 猎物搜索

除了 bubble-net 狩猎策略,座头鲸需要随机搜索猎物,该过程数学模型如下:

$$D = |C \cdot X_{\text{rand}}(t) - X(t)| \quad (7)$$

$$X(t+1) = X_{\text{rand}}(t) - A \cdot D \quad (8)$$

其中, $X_{\text{rand}}(t)$ 是从种群中随机选择的搜索代理位置向量。

为了保证探索和收敛,当 $|A| \geq 1$ 时,随机选择的搜索代理成为更新其他搜索代理位置的关键点。在其他情况下($|A| < 1$ 时),目前最优解位置在更新其他搜索代理中起到枢纽点的作用。

2 改进的鲸鱼优化算法

WOA 相比其他先进的启发式算法具有操作简单、调节参数少的优势,该算法只包括 2 个需要调整的主要内部参数(A 和 C)。搜索矢量 A 的自适应变化策略,使 WOA 拥有良好的平衡开发和探索的能力及高局部最优规避能力。但是正是因为 A 的随机机制,使得基本 WOA 存在收敛速度慢、收敛精度低的问题。本文针对上述问题,提出 MWOA。

2.1 基于混沌理论的种群初始化

基于种群的启发式优化算法具有共同的特征,其全局收敛速度和解的质量受初始种群质量影响,

多样性程度较高的初始种群可以提高算法的寻优性能^[12]。但是,基本 WOA 在进行迭代前,随机产生的初始种群不能有效保证搜索代理在搜索空间均匀分布^[13],从而在迭代过程中导致搜索效率降低。

混沌具有随机性、遍历性、对初始条件极度敏感等特点,其能在一定范围内按自身规律不重复地遍历所有状态。利用混沌运动的这些性质可以进行种群初始化,保证初始种群的多样性^[14]。由于分段 Logistic 混沌映射的非线性性质,保证了生成混沌序列时不需要进行扰动运算^[15],可以提升算法生成的效率,因此,本文采用文献[15]中的分段 Logistic 混沌映射对种群进行初始化,该过程计算表达式如下:

$$x_{i+1} = \begin{cases} 4\mu x_i(0.5 - x_i), & 0 \leq x_i < 0.5 \\ 1 - 4\mu x_i(0.5 - x_i)(1 - x_i), & 0.5 \leq x_i \leq 1 \end{cases} \quad (9)$$

其中, x_0 是 $(0, 1)$ 之间的随机量, Logistic 参数 μ 取值范围为: $3.569\ 9 \cdots \leq \mu \leq 4$ 。

基于分段 Logistic 混沌映射种群初始化的步骤如下(座头鲸种群数量 N , 候选解维度 D , 当前迭代次数 t , 大整数 L):

1) 随机产生一个每个分量数值在 $(0, 1)$ 之间的 D 维向量 $\mathbf{x}_1 = (x_{11}, x_{12}, \cdots, x_{1D})$, 根据式(9)生成 $L + 2N$ 个向量 $\mathbf{x}_{i+1j} = f(\mathbf{x}_{ij})$, $i = 1, 2, \cdots, L + 2N; j = 1, 2, \cdots, D$, 取最后 $2N$ 个向量 $\mathbf{x}_{L+1}, \mathbf{x}_{L+2}, \cdots, \mathbf{x}_{L+2N}$;

2) 根据 $z_{ij} = \min_j + x_{ij}(\max_j - \min_j)$, 将 \mathbf{x}_i 的第 j 个分量映射到区间 $[\min_j, \max_j]$ 内;

3) 计算适应度值, 选择适应度值最小的 N 个向量作为初始种群位置。

2.2 非线性自适应权重

文献[16]提出了惯性权重线性下降策略并应用到 PSO 算法中, 实验证明, 较大的惯性权重有利于粒子全局寻优; 反之, 则利于局部开发、加快收敛速度。因此, 惯性权重对算法收敛速度和全局寻优能力都有重要影响。由于 WOA 在优化过程中是非线性变化的, 惯性权重线性下降策略无法体现实际的优化搜索过程, 又考虑到各搜索代理间的状态差异性, 为此, 本文提出基于搜索代理当前状态的非线性自适应权重策略, 其表达式如下:

$$w(t)_i = \begin{cases} w_1 - \frac{(w_2 - w_1)}{T_{\max}} \cdot \frac{f(t)_i - f(t)_{\min}}{f(t)_{\max} - f(t)_{\min}} & f(t)_i < f(t)_{\text{avg}} \\ w_2 + \frac{(w_2 - w_1)}{T_{\max}} \cdot \frac{f(t)_i - f(t)_{\text{avg}}}{f(t)_{\max} - f(t)_{\min}} & f(t)_i \geq f(t)_{\text{avg}} \end{cases} \quad (10)$$

其中, $w(t)_i$ 为第 i 个搜索代理在第 t 次迭代的权重, T_{\max} 是最大迭代次数, w_1 、 w_2 分别为初始最小权重和最大权重, $f(t)_{\text{avg}}$ 为第 t 次迭代种群的平均适应度值, $f(t)_{\min}$ 、 $f(t)_{\max}$ 分别为第 t 次迭代种群最小适应度值和最大适应度值。

由式(10)可知, 搜索代理适应度值小于平均适应度值时权重 w 较小, 从而保证该搜索代理在最优解邻域空间中精细搜索; 反之, 适应度值大于平均适应度值时, 权重 w 较大, 使得该搜索代理可以在大范围空间寻找更优的解。 w 随着当前种群平均适应度值和个体搜索代理适应度值自适应变化, 有效提高了 WOA 的收敛精度和收敛速度。

将式(10)代入式(6), 改进后的位置更新数学模型如下:

$$\mathbf{X}(t+1) = \begin{cases} w(t) \cdot \mathbf{X}^*(t) - \mathbf{A} \cdot \mathbf{D}, & p < 0.5 \\ w(t) \cdot \mathbf{X}^*(t) + \mathbf{D}' \cdot e^{bl} \cdot \cos(2\pi l), & p \geq 0.5 \end{cases} \quad (11)$$

2.3 算法步骤

MWOA 具体步骤如下:

1) 初始化参数。座头鲸种群数量 N , 候选解维度 D , 大整数 L , 最大迭代次数 T_{\max} , 初始最小权重 w_1 和最大权重 w_2 。

2) 利用混沌初始化产生 $L + 2N$ 个向量, 选择最后 $2N$ 个向量映射到候选解空间, 作为座头鲸种群位置。

3) 计算每一头座头鲸相应适应度值, 选择适应度值最小的 N 个向量作为初始种群位置。

4) 根据目标函数分别计算每个搜索代理的适应度值, 记录最优适应度值和对应位置向量。

5) 更新每个搜索代理的参数 a 、 \mathbf{A} 、 \mathbf{C} 、 \mathbf{l} 、 p 和 w 。

6) 如果 $|\mathbf{A}| \geq 1$, 按式(8)更新下一代的位置。

7) 如果 $|\mathbf{A}| < 1$, 按式(11)更新下一代的位置。

8) 判断是否达到循环结束条件, 若是, 结束算法, 输出最优解位置; 否则, 返回步骤 4)。

3 仿真实验与分析

3.1 基准测试函数

为了评估提出的 MWOA 寻优性能, 本文选用 6 个典型的基准测试函数(如表 1 所示)进行仿真实验。6 个基准测试函数分为 2 组, $f_1 \sim f_3$ 是可变维单模态函数, 可以用来验证算法的收敛速度和收敛精度; $f_4 \sim f_6$ 是可变维多模态函数, 可以用来验证算法的全局寻优能力和局部最优规避能力。

表1 基准测试函数

函数	搜索范围	基准函数理论最小值
$f_1(x) = \sum_{i=1}^n x_i^2$	$[-100, 100]$	0
$f_2(x) = \sum_{i=1}^n x_i + \prod_{i=1}^n x_i $	$[-10, 10]$	0
$f_3(x) = \sum_{i=1}^n (\sum_{j=1}^i x_j)^2$	$[-100, 100]$	0
$f_4(x) = \sum_{i=1}^n [x_i^2 - 10\cos(2\pi x_i) + 10]$	$[-5.12, 5.12]$	0
$f_5(x) = -20\exp(-0.2\sqrt{\frac{1}{n}\sum_{i=1}^n x_i^2}) - \exp(\frac{1}{n}\sum_{i=1}^n \cos(2\pi x_i)) + 20 + e$	$[-32, 32]$	0
$f_6(x) = 0.1 \sin^2(3\pi x_1) + \sum_{i=1}^n (x_i - 1)^2[1 + \sin^2(3\pi x_1 + 1)] + (x_n - 1)^2[1 + \sin^2(2\pi x_n)]\} + \sum_{i=1}^n \mu(x_i, 5, 100, 4)$	$[-50, 50]$	0

3.2 实验结果与分析

3.2.1 MWOA、WOA、AWOA 性能对比

将 MWOA、WOA、AWOA 的性能进行对比。实验参数设置如下:座头鲸种群数量均为 30,最大迭代次数均为 1 500,基准测试函数维度设置 30 和 100 两组。在 AWOA 中,其余参数设定参照文献[7],惯性权重最大值 $w' = 0.08$,惯性权

重最小值 $w'' = 0.01$ 。在 MWOA 中, $L = 1\ 000$, $w_1 = 0.01$, $w_2 = 0.4$ (经过大量实验得出)。为消除算法的随机性影响,3 种算法均连续独立运行 20 次,记录 20 次实验中各基准函数最优适应度的最优值、最差值、平均值、标准差以及 20 次实验达到最优适应度值所需平均迭代次数(在表 2 中将其简述为迭代次数),仿真结果如表 2 所示。

表2 WOA、AWOA、MWOA 性能比较

函数	参数	WOA		AWOA		MWOA	
		30	100	30	100	30	100
f_1	最优值	1.81E-248	1.71E-242	0	0	0	0
	最差值	3.25E-224	5.46E-219	0	0	0	0
	平均值	1.62E-225	2.73E-220	0	0	0	0
	标准差	0	0	0	0	0	0
	迭代次数	1 500	1 500	794	813	766	779
f_2	最优值	2.83E-170	5.94E-164	0	0	0	0
	最差值	2.00E-154	2.37E-154	0	0	0	0
	平均值	1.34E-155	2.65E-155	0	0	0	0
	标准差	0	0	0	0	0	0
	迭代次数	1 500	1 500	915	984	897	901
f_3	最优值	1.11E-01	1.34E+01	0	0	0	0
	最差值	8.51E+01	9.06E+01	0	0	0	0
	平均值	3.26E+01	6.27E+01	0	0	0	0
	标准差	3.06E+01	2.43E+01	0	0	0	0
	迭代次数	1 500	1 500	979	983	879	889
f_4	最优值	0	0	0	0	0	0
	最差值	0	0	0	0	0	0
	平均值	0	0	0	0	0	0
	标准差	0	0	0	0	0	0
	迭代次数	358	362	33	50	13	20
f_5	最优值	8.88E-16	8.88E-16	8.88E-16	8.88E-16	8.88E-16	8.88E-16
	最差值	7.99E-15	7.99E-15	8.88E-16	8.88E-16	8.88E-16	8.88E-16
	平均值	3.91E-15	4.26E-15	8.88E-16	8.88E-16	8.88E-16	8.88E-16
	标准差	2.65E-15	2.70E-15	0	0	0	0
	迭代次数	—	—	295	320	210	243
f_6	最优值	1.54E-02	4.95E-01	5.35E-02	1.89E-01	2.93E-02	6.61E-02
	最差值	4.55E-01	1.94E+00	3.37E-01	1.51E+00	3.18E-01	8.15E-01
	平均值	1.79E-01	9.87E-01	1.94E-01	7.57E-01	1.57E-01	5.36E-01
	标准差	1.36E-01	3.31E-01	7.62E-02	2.80E-01	8.81E-02	2.05E-01
	迭代次数	1 500	1 500	1 500	1 500	1 500	1 500

从表 2 中可以看出,在 $f_1 \sim f_6$ 中, MWOA 获得的平均最优适应度值、标准差和迭代次数均优于 WOA,这充分验证了相比 WOA, MWOA 在收敛速度、收敛精度以及算法稳定性上都有较大的提升。在 $f_1 \sim f_4$ 中, MWOA 和 AWOA 均可达到目标最优值,但是 MWOA 较 AWOA 在迭代次数上有所减少,说明 MWOA 收敛速度优于 AWOA。在 f_5, f_6 中, MWOA 和 AWOA 均未达到目标最优值(可以适当增加迭代次数,提高算法的收敛精度),但是在相同收敛精度的情况下, MWOA 收敛速度优于 AWOA。而收敛次数相当时, MWOA 收敛精度优于 AWOA。

随着基准测试函数维度的增加,3 种算法迭代次数和收敛精度均未有明显的增加,这在一定程度上说明,随着问题复杂度增加,3 种算法依然有较强的优化效果。由于篇幅有限,本文只给出了基准测试函数维度为 30 时 WOA、MWOA 和 AWOA 的收敛曲线对比,如图 2 ~ 图 7 所示(纵坐标“目前最好值”表示当前迭代次数最优收敛值),以及算法计算时间对比,如表 3 所示。

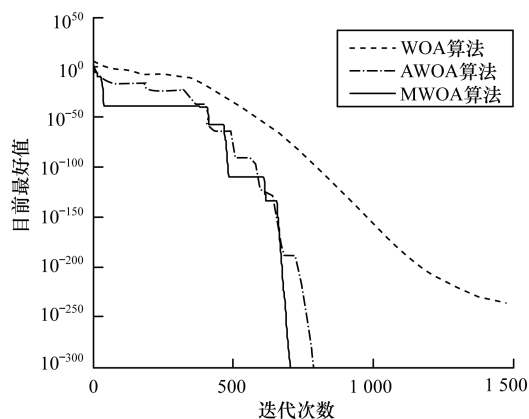


图 2 3 种算法对 f_1 的性能比较

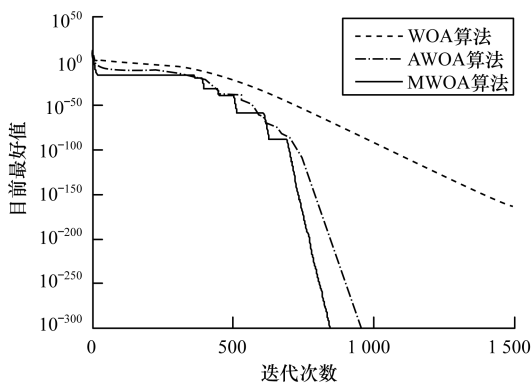


图 3 3 种算法对 f_2 的性能比较




图 4 3 种算法对 f_3 的性能比较




图 5 3 种算法对 f_4 的性能比较




图 6 3 种算法对 f_5 的性能比较




图 7 3 种算法对 f_6 的性能比较

表 3 3 种算法计算时间结果

函数	WOA	AWOA	MWOA
f_1	1.948	1.028	0.833
f_2	2.115	1.287	0.978
f_3	2.003	1.265	0.861
f_4	0.560	0.203	0.043
f_5	0.888	0.363	0.096
f_6	2.166	2.047	1.673

从图 2 ~ 图 7 中可以看出,在给定基准测试函数中,MWOA 在初始迭代时有较高的寻优效率,在整个寻优过程中不仅有较高的收敛精度,更具有较快的收敛速度。这些结果表明,MWOA 得益于多样性程度较高的初始种群和非线性自适应权重策略,这些改进帮助 MWOA 在初始迭代中快速寻找搜索空间中有希望的区域,在寻优过程中协调全局探索和局部开发能力,更快地收敛到最优。

从表 3 中可以看出,在 6 个基准测试函数结果中,MWOA 计算时间均优于 WOA 和 AWOA。由于加入了非线性自适应权重策略,MWOA 中搜索代理的权重随着当前种群平均适应度值和个体搜索代理适应度值自适应变化,减少了 WOA 存在的部分无效迭代,从而有效提高了算法的收敛速度。

3.2.2 MWOA、PSO、GSA 性能对比

本文选取改进的 PSO^[14]、改进的 GSA^[17] 和 MWOA 做性能对比。实验参数设置如下:最大迭代次数均为 1 500,基准测试函数维度均为 50,种群数均为 30。PSO 其余参数设置:学习因子 $c_1 = c_2 = 2$,惯性权重 $w_{\min} = 0.4$, $w_{\max} = 0.9$;GSA 其余参数设置:常量 $G_0 = 100$,变化量 $\alpha = 20$,权值 $C_{\max} = 0.9$, $C_{\min} = 0.6$;MWOA 其余参数设置参照 3.2.1 节。实验结果如表 4 所示。

表 4 MWOA、PSO、GSA 性能比较

函数	算法	迭代次数	平均值	标准差
f_1	MWOA	788	0	0
	PSO	1 500	1.821 19	0.433 71
	GSA	1 500	5.44E-18	1.14E-18
f_2	MWOA	907	0	0
	PSO	1 500	7.402 21	0.783 90
	GSA	1 500	0.000 39	0.001 64
f_3	MWOA	889	0	0
	PSO	1 500	0.476 66	0.058 82
	GSA	1 500	74.262 84	23.391 64
f_4	MWOA	37	0	0
	PSO	1 500	212.121 49	25.660 12
	GSA	1 500	219.188 35	53.296 04
f_5	MWOA	213	8.88E-16	2.02E-31
	PSO	1 500	1.879 41	0.254 10
	GSA	1 500	11.429 86	7.823 09
f_6	MWOA	1 500	0.309 71	1.413 70
	PSO	1 500	4.778 46	0.633 63
	GSA	1 500	6.871 90	8.004 38

从表 4 运行结果可知,MWOA 与 PSO、GSA 相比,无论是在收敛速度还是收敛精度方面,在 6 个基准测试函数上均表现出足够的竞争力。MWOA 的高局部最优规避能力和快速收敛能力得益于式(8)和式(11),2 个表达式分别完成 2 个阶段(全局探索和局部开发)搜索代理位置的更新。而 PSO 和 GSA 利用一个表达式来更新搜索代理的位置,没有专门用于探索或开发的迭代,因此,增加了其局部最优中停止的可能性。

4 结束语

本文介绍 WOA 的优化原理,针对 WOA 收敛速度慢、收敛精度低的问题,提出改进算法 MWOA,该算法主要研究种群初始化机制和非线性自适应权重策略。对 6 个典型基准测试函数进行仿真实验,由仿真结果可知,MWOA 的平均适应度值和迭代次数均优于对比算法,这表明该算法在总体性能上具有优势。如何从理论上对该算法进行收敛性分析,将是今后研究的重点。

参考文献

- [1] WOLPERT D H, MACREADY W G. No Free Lunch Theorems for Optimization[J]. IEEE Transactions on Evolutionary Computation, 1997, 1(1): 67-82.
- [2] STORN R, PRICE K. Differential Evolution-A Simple and Efficient Heuristic for Global Optimization over Continuous Spaces[J]. Journal of Global Optimization, 1997, 11(4): 341-359.
- [3] GLOVER F. Tabu Search-part I[J]. ORSA Journal on Computing, 1989, 1(3): 190-206.
- [4] RASHEDI E, NEZAMABADI-POUR H, SARYAZDI S. GSA: A Gravitational Search Algorithm[J]. Information Sciences, 2009, 179(13): 2232-2248.
- [5] GEEM Z W, KIM J H, LOGANATHAN G V. A New Heuristic Optimization Algorithm: Harmony Search[J]. Simulation, 2001, 76(2): 60-68.
- [6] MIRJALILI S, LEWIS A. The Whale Optimization Algorithm[J]. Advances in Engineering Software, 2016, 95: 51-67.
- [7] 牛培峰, 吴志良, 马云鹏, 等. 基于鲸鱼优化算法的汽轮机热耗率模型预测[J]. 化工学报, 2017, 68(3): 1049-1057.
- [8] KAVEH A. Sizing Optimization of Skeletal Structures Using the Enhanced Whale Optimization Algorithm[M]// KAVEH A. Applications of Metaheuristic Optimization Algorithms in Civil Engineering. Berlin, Germany: Springer, 2017: 47-69.

(下转第 219 页)

参考文献

- [1] WU S, LIU Q, WANG L, et al. Contextual Operation for Recommender Systems [J]. IEEE Transactions on Knowledge and Data Engineering, 2016, 28(8): 2000-2012.
- [2] TANG Q, WANG J. Privacy-preserving Context-aware Recommender Systems: Analysis and New Solutions [C]//Proceedings of European Symposium on Research in Computer Security. Berlin, Germany: Springer, 2015: 101-119.
- [3] 王立才, 孟祥武, 张玉洁, 等. 上下文感知推荐系统[J]. 软件学报, 2012, 23(1): 1-20.
- [4] ZHU T, LI G, ZHOU W, et al. Privacy-preserving Topic Model for Tagging Recommender Systems [J]. Knowledge and Information Systems, 2016, 46(1): 33-58.
- [5] 柴瑞敏, 冯慧慧. 基于聚类的高效(K, L)-匿名隐私保护[J]. 计算机工程, 2015, 41(1): 139-142.
- [6] 满娜. 一种基于K-匿名的隐私保护算法[D]. 哈尔滨: 哈尔滨工程大学, 2011.
- [7] LIU B, HENGARTNER U. Privacy-preserving Social Recommendations in Geosocial Networks [C]//Proceedings of the 11th International Conference on Privacy, Security and Trust. Washington D. C., USA: IEEE Press, 2013: 69-76.
- [8] CLEMENTE F J G. A Privacy-preserving Recommender System for Mobile Commerce [C]//Proceedings of IEEE Conference on Communications and Network Security. Washington D. C., USA: IEEE Press, 2015: 725-726.
- [9] 徐南, 王新生. 协同过滤系统隐私保护和推荐准确性研究[J]. 计算机工程, 2010, 36(23): 82-84.
- [10] 夏建勋, 吴非, 谢长生. 应用数据填充缓解稀疏问题实现个性化推荐[J]. 计算机工程与科学, 2013, 35(5): 15-19.
- [11] JAGTAP P, JOSHI A, FININ T, et al. Preserving Privacy in Context-aware Systems [C]//Proceedings of IEEE International Conference on Semantic Computing. Washington D. C., USA: IEEE Press, 2011: 149-153.
- [12] 叶阿勇, 李亚成, 马建峰, 等. 基于服务相似性的k-匿名位置隐私保护方法[J]. 通信学报, 2014, 35(11): 162-169.
- [13] 李东胜. 基于兴趣与保护隐私的在线社区推荐技术研究[D]. 上海: 复旦大学, 2012.
- [9] SAYED G I, DARWISH A, HASSANIEN A E, et al. Breast Cancer Diagnosis Approach Based on Meta-heuristic Optimization Algorithm Inspired by the Bubble-net Hunting Strategy of Whales [C]//Proceedings of International Conference on Genetic and Evolutionary Computing. Berlin, Germany: Springer, 2016: 306-313.
- [10] HORNG M F, DAO T K, SHIEH C S, et al. A Multi-objective Optimal Vehicle Fuel Consumption Based on Whale Optimization Algorithm [C]//Proceedings of the 12th International Conference on Intelligent Information Hiding and Multimedia Signal. Berlin, Germany: Springer, 2017: 371-380.
- [11] PARMAR S A, PANDYA M H, BHOYE M, et al. Optimal Active and Reactive Power Dispatch Problem Solution Using Whale Optimization Algorithm [C]//Proceedings of 2016 International Conference on Energy Efficient Technologies of Sustainability. Washington D. C., USA: IEEE Press, 2016: 491-496.
- [12] HAUPT R L, HAUPT S E. Practical Genetic Algorithms [M]. Hoboken, USA: John Wiley and Sons Inc., 2004.
- [13] 龙文, 赵东泉, 徐松金. 求解约束优化问题的改进灰狼优化算法[J]. 计算机应用, 2015, 35(9): 2590-2595.
- [14] 高尚, 杨静宇. 混沌粒子群优化算法研究[J]. 模式识别与人工智能, 2006, 19(2): 266-270.
- [15] 范九伦, 张雪锋. 分段 Logistic 混沌映射及其性能分析[J]. 电子学报, 2009, 37(4): 720-725.
- [16] SHI Y, EBERHART R. A Modified Particle Swarm Optimizer [C]//Proceedings of 1998 IEEE World Congress on Computational Intelligence. Washington D. C., USA: IEEE Press, 1998: 69-73.
- [17] 徐遥, 王士同. 引力搜索算法的改进[J]. 计算机工程与应用, 2011, 47(35): 188-192.

编辑 吴云芳

编辑 吴云芳

(上接第213页)